

ACADEMIC CURRICULUM VITAE

白有辉

中国科学技术大学特任副研究员 | 研究方向：大模型分布式并行计算

youhuibai@ustc.edu.cn | (+86) 183-5652-1691 | youhuibai.github.io

研究概况 主要从事大模型分布式并行计算研究，围绕训练数据流水线、自动并行、长上下文与稀疏注意力、MoE 推理及异构算子优化开展算法-系统-硬件协同研究；成果发表于 OSDI、SOSP、HPCA、TPDS、ICPP、CVPR、AAAI、TMLR、ACL 等会议和期刊，Google Scholar 总引用量 260+。

教育背景

2016.09 - 2021.06 中国科学技术大学 | 计算机科学与技术学院，计算机系统结构专业，博士

导师：许胤龙教授、李诚特任研究员

2012.09 - 2016.06 中国科学技术大学 | 计算机科学与技术学院，计算机科学与技术专业，本科

工作经历

2025.06 - 至今 中国科学技术大学 | 计算机科学与技术学院，特任副研究员

科研方向：围绕大模型训练数据流水线、稀疏注意力、MoE 推理负载均衡、异构芯片算子生成与长上下文管理开展算法-系统-硬件协同研究。

代表进展：大规模 LLM 预训练数据流水线研究发表于 USENIX OSDI 2026 并获 Jay Lepreau Best Paper Award；相关优化在字节跳动训练任务中累计节约数万 GPU 卡时。研发面向异构芯片的算子生成方法与动态 Top-K 路由 MoE 推理框架；已支持华为昇腾 910B/C，单卡可运行 2 个 70 亿参数模型训推任务，预填充速度最高提升 2 倍，部分成果应用落地至中科类脑云平台。

科研项目：主持国家自然科学基金青年科学基金项目（C 类）及字节跳动、腾讯等横向项目，作为技术骨干参与国家科技重大专项和合肥市揭榜挂帅项目。

2021.08 - 2025.06 华为技术有限公司 | 2012 实验室中央研究院，主任工程师

昇腾算子优化：面向 910A/910B 芯片设计 FlashAttention 融合算子优化策略；910B 方案性能提升 30%，达到 NVIDIA A100 同类算子 0.9 倍效率，并落地 CANN 8.0 软件包。

大模型训练加速：提出自适应重计算及多维并行计算-通信重叠策略，支撑科大讯飞星火 X1 千卡昇腾 910B 训练任务，端到端训练速度提升 60% 以上；相关能力落地 MindSpeed。

长上下文与推理加速：提出 KV Cache 压缩、分阶段训短推长和 Top-K 稀疏注意力方案；长序列 KV Cache 内存占用降低 50% 以上，Top-K 方案在长序列场景提升推理速度 30% 以上，并落地 CANN、MindIE 及盘古模型。

所获荣誉

个人荣誉

2026 USENIX OSDI Jay Lepreau Best Paper Award。OSDI 自 1994 年举办以来，首次由中国内地机构作为第一完成单位获得该奖项，并且论文作者全部来自国内高校、科研机构和企业，实现了我国科研团队在国际计算机系统顶级会议上的重要突破。

2025 华为大禹治水攻关项目特等奖：公司级攻关项目最高荣誉，核心技术为 Top-K 稀疏注意力推理加速。

2025 闪存存储 SPDT 总裁奖 - 众志成城奖：面向华为昇腾芯片的推理加速相关技术落地华为存储产品线。

2025 华为公司火花奖一等奖：分阶段训短推长算法将大模型推理长度扩展至 1M 级别并落地盘古模型。

2024 世界人工智能大会青年优秀论文奖：全球 10 篇，获奖单位包括加州大学伯克利分校、新加坡国立大学等海外名校，论文包括基础学科顶刊 Nature、人工智能顶会 ICLR 和 ICML 等，是唯一入选的人工智能系统会议论文。

2024 华为公司火花奖一等奖：面向长序列推理的 Key 聚类、Value 融合 KV Cache 压缩方法。

2024 华为中央研究院创新先锋一等奖：基于昇腾分离式架构的 Attention 融合算子并行算法 TurboAttention。

2023 ACM SIGCSE 优秀博士论文奖：全国 2 人；获奖论文《并行与分布式神经网络训练中数据通路的优化》。

2023 华为公司金牌团队奖、公司年度工作会议奖 - 创新与技术突破奖：作为核心骨干参与昇腾算子优化会战。

2023 华为中央研究院创新先锋一等奖：华为昇腾 910A 架构友好的 FlashAttention 融合算子优化。

2023 计算产品线攻坚克难奖、优秀个人高质量交付奖：支撑大模型训练平台及关键客户项目交付。

2022-2024 多次获华为总裁嘉奖令。在产品交付、技术竞争力提升和生态建设等方面取得关键成果。

2021 安徽省优秀毕业生。中国科学技术大学计算机学院 1 人。

指导学生获奖

2026 指导学生获全国大学生计算机系统能力大赛编译系统设计赛（华为毕昇杯）**全国一等奖**；基于 Triton-Ascend 构建昇腾亲和算子，Cube 利用率达到 90%+。

2026 指导谭昊玥获**商汤奖学金提名奖**，相关工作 AdaCluster 发表于 CVPR 2026。

2025 指导王晨晗获 SOSP Student Research Competition **全球亚军**，研究方向为大模型训练 Checkpoint 管理系统。

2025 指导龚平入选字节跳动 **Top Seed** 实习生计划（面向全球前 5% 顶尖 AI 人才）。

论文列表（*表示通讯作者）

2026

- Luofan Chen, Chenhan Wang, Weidong Zhang, Jinxin Chi, Hequan Zhang, Zanbo Wang, Chenyuan Wang, Lishu Luo, Sijin Wu, Junqi Hu, Jun Wang, Cheng Chen, Lixin Huang, Liyang Zhao, Yong Tian, Jun Guo, **Youhui Bai***, Wencong Xiao, Kang Chen, Cheng Li. **Teaching the Old Dog New Tricks: Building Efficient Data Pipelines for Large-Scale LLM Pre-Training (Operational Systems)**. *20th USENIX Symposium on Operating Systems Design and Implementation (OSDI)*, July 2026. Best Paper.
- Jiaan Zhu, Qinghe Wang, Long Zhao, Chizheng Fang, Zewen Jin, **Youhui Bai***, Zhiqi Lin, Cheng Li. **nnScaler-M: Constraint-Guided and Placement-Aware Parallelization Plan Generation for Deep Learning Training**. *IEEE Transactions on Parallel and Distributed Systems (TPDS)*, July 2026.
- Jie Hu, Shengnan Wang, Yutong He, Ping Gong, Jiawei Yi, Juncheng Zhang, **Youhui Bai**, Renhai Chen, Gong Zhang, Cheng Li, Kun Yuan. **CentroidKV: Efficient Long-Context LLM Inference via KV Cache Clustering**. *Transactions on Machine Learning Research (TMLR)*, June 2026.
- Haoyue Tan, Shengnan Wang, Yulin Qiao, Juncheng Zhang, **Youhui Bai***, Ping Gong, Zewen Jin, Cheng Li. **AdaCluster: Adaptive Query-Key Clustering for Sparse Attention in Video Generation**. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2026.
- Long Zhao, Qinghe Wang, Jiaan Zhu, **Youhui Bai***, Zewen Jin, Chaoyi Ruan, Shengnan Wang, Cheng Li. **Accelerating Long-Tail Generation in Synchronous RLHF Training via Adaptive Tensor Parallelism**. *International Conference on Parallel Processing (ICPP)*, 2026.
- Zewen Jin, Shen Fu, Chengjie Tang, **Youhui Bai***, Shengnan Wang, Jiaan Zhu, Chizheng Fang, Ping Gong, Cheng Li. **SMIDT: High-Performance Inference Framework for MoE Models with Dynamic Top-K Routing**. *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI)*, March 2026.
- Guanbin Xu, ZhenGuo Xu, Yuzhe Li, **Youhui Bai***, Ping Gong, Chaoyi Ruan, Cheng Li. **Lagom: Unleashing the Power of Communication and Computation Overlapping for Distributed LLM Training**. *arXiv preprint arXiv:2602.20656*, February 2026.

2025

- Jiawei Yi, Ping Gong, **Youhui Bai***, Jiaqi Ruan, Shengnan Wang, Pengcheng Wang, Haibo Wang, Weiguang Wang, Xia Zhu, Feng Wu, Cheng Li. **CLO: Efficient LLM Inference System with CPU-Light KVCache Offloading via Algorithm-System Co-Design**. *arXiv preprint arXiv:2511.14510*, November 2025.
- Jie Hu, Shengnan Wang, Yutong He, Ping Gong, Jiawei Yi, Juncheng Zhang, **Youhui Bai**, Renhai Chen, Gong Zhang, Cheng Li, Kun Yuan. **Efficient Long-Context LLM Inference via KV Cache Clustering**. *arXiv preprint arXiv:2506.11418*, June 2025.
- Ping Gong, Jiawei Yi, Shengnan Wang, Juncheng Zhang, Zewen Jin, Ouxiang Zhou, Ruibo Liu, Guanbin Xu, **Youhui Bai**, Bowen Ye, Kun Yuan, Tong Yang, Gong Zhang, Renhai Chen, Feng Wu, Cheng Li. **HATA: Trainable and Hardware-Efficient Hash-Aware Top-k Attention for Scalable Large Model Inference**. *Findings of the Association for Computational Linguistics (ACL)*, May 2025.
- Zewen Jin, Shengnan Wang, Jiaan Zhu, Hongrui Zhan, **Youhui Bai**, Lin Zhang, Zhenyu Ming, Cheng Li. **BigMac: A Communication-Efficient Mixture-of-Experts Model Structure for Fast Training and Inference**. *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI)*, March 2025.

2024

12. Shengnan Wang, **Youhui Bai**, Lin Zhang, Pingyi Zhou, Shixiong Zhao, Gong Zhang, Sen Wang, Renhai Chen, Hua Xu, Hongwei Sun. **XL3M: A Training-free Framework for LLM Length Extension Based on Segment-wise Inference**. *arXiv preprint arXiv:2405.17755*, May 2024.

2023

13. Peng Liang, Yu Tang, Xiaoda Zhang, **Youhui Bai**, Teng Su, Linbo Qiao, Zhiquan Lai, Dongsheng Li. **A Survey on Auto-Parallelism of Neural Networks Training**. *IEEE Transactions on Parallel and Distributed Systems (TPDS)*, May 2023.
14. Hao Wu, Shiyi Wang, **Youhui Bai***, Cheng Li, Quan Zhou, Jun Yi, Feng Yan, Ruichuan Chen, Yinlong Xu. **A Generic, High-Performance, Compression-Aware Framework for Data Parallel DNN Training**. *IEEE Transactions on Parallel and Distributed Systems (TPDS)*, April 2023.
15. Quan Zhou, Haiquan Wang, Xiaoyan Yu, Cheng Li, **Youhui Bai**, Feng Yan, Yinlong Xu. **MPress: Democratizing Billion-Scale Model Training on Multi-GPU Servers via Memory-Saving Inter-Operator Parallelism**. *IEEE International Symposium on High-Performance Computer Architecture (HPCA)*, February 2023.

2021

16. **Youhui Bai**, Cheng Li, Quan Zhou, Jun Yi, Ping Gong, Feng Yan, Ruichuan Chen, Yinlong Xu. **Gradient Compression Supercharged High-Performance Data Parallel DNN Training**. *Proceedings of the ACM Symposium on Operating Systems Principles (SOSP)*, October 2021.
17. **Youhui Bai**, Cheng Li, Zhiqi Lin, Yufei Wu, Youshan Miao, Yunxin Liu, Yinlong Xu. **Efficient Data Loader for Fast Sampling-based GNN Training on Large Graphs**. *GNNSys Workshop*, April 2021.
18. **Youhui Bai**, Cheng Li, Zhiqi Lin, Yufei Wu, Youshan Miao, Yunxin Liu, Yinlong Xu. **Efficient Data Loader for Fast Sampling-based GNN Training on Large Graphs**. *IEEE Transactions on Parallel and Distributed Systems (TPDS)*, March 2021.

学术服务

- 2026 第二届前沿人工智能系统研讨会（FAISys 2026）程序委员会委员（PC Member）
- 2026 ACM SIGOPS Annual Technical Conference（ATC 2026）Artifact Evaluation 程序委员会委员
- 2026 The International Workshop on Big Memory（BigMem 2026）程序委员会委员
- 2026 ChinaSys 2026 春季会议程序委员会委员
- 2026 Annual Meeting of the Association for Computational Linguistics（ACL，CCF A）审稿人
- 2026.03 - 至今 《小型微型计算机系统》青年编委
- 2026.07 - 至今 CCF 体系结构专业委员会执行委员
- 2025.07 - 至今 CCF 分布式计算与系统专业委员会执行委员
- 长期 IEEE Transactions on Mobile Computing（TMC，CCF A）审稿人
- 长期 Frontiers of Computer Science（FCS，CCF B）审稿人
- 长期 CCF Transactions on High Performance Computing（THPC，CCF C）审稿人
- 2025.07.25 第二届分布式计算大会稀疏注意力落地实现赛题命题与裁判；全国十余支队伍参赛

受邀报告

- 2026.04.28 龙蜥智算联盟“聚力前行 - 智算时代的基础设施创新”Meetup。主题：面向 Multi-Agent 场景的长上下文管理方法；线下 50+人，线上参与 15,000+人。
- 2026.01.31 SGLang、阿里云、龙蜥社区圆桌讨论。主题：智算新生态：异构 AI 算力底座如何驱动大模型全场景落地？；线下 50+人，线上观看 18 万+人次。
- 2026.01.28 阿里云智能产技专委会。主题：KV Cache 的层次化管理；线上线下总人数 50+。
- 2025.08.14 CCF 全国高性能计算学术大会（内蒙古鄂尔多斯）。主题：面向大模型的昇腾底层算子自动生成与优化工具；线下 30+人。
- 2025.07.24 “新雁聚江淮·人工智能+”博士后学术交流（安徽合肥）。主题：面向大模型高性能计算的算法-系统-硬件协同创新研究；线下 30+人。